

MODELOS PREDITIVOS PARA ANTECIPAÇÃO DE COMPORTAMENTOS-PROBLEMA EM ABA

Revisão crítica da literatura e proposta metodológica para dados da
plataforma bHave

Artigo técnico-acadêmico

Análise do Comportamento Aplicada • ciência de dados • machine learning • saúde digital

Data de atualização da busca: 13 de julho de 2026

Idioma: português | Referências: APA 7ª edição

Nota de integração técnica: esta versão combina a revisão crítica da literatura e a proposta metodológica com a implementação MVP realizada no Sellas Project. Foram incorporados adapter configurável para a API bHave, calibração explícita de probabilidade, persistência versionada de modelos, validação temporal por paciente e período, monitoramento de drift e checklist LGPD/governança/regulatório antes de uso real.

Nota de escopo, rigor e limites da busca

Este documento apresenta uma revisão acadêmica estruturada e crítica, acompanhada de uma proposta metodológica aplicada. A busca foi atualizada em 13 de julho de 2026 e priorizou PubMed, periódicos e páginas oficiais de editoras científicas, IEEE, ACM, Springer Nature, Wiley, Taylor & Francis, MDPI, JAMA Network e fontes regulatórias brasileiras. O Google Scholar foi utilizado como mecanismo complementar de descoberta e rastreamento de citações. Scopus e algumas bases comerciais não puderam ser auditadas de forma exaustiva sem autenticação institucional; por isso, o trabalho não deve ser descrito como revisão sistemática registrada ou revisão exaustiva de todas as bases.

Foram priorizados trabalhos revisados por pares que estimam ocorrência futura, risco, intensidade ou severidade de comportamentos desafiadores, além de estudos de detecção/classificação que oferecem métodos transferíveis. Quando um estudo detecta um comportamento já em curso, em vez de prever um evento futuro, essa diferença é assinalada explicitamente. Não foram inventados autores, resultados ou identificadores. Dados não claramente disponíveis nas fontes acessíveis são marcados como “não informado” ou “não verificável na fonte acessível”.

Interpretação clínica obrigatória

Uma previsão estatística não identifica a função do comportamento, não demonstra causalidade e não substitui avaliação funcional, análise experimental, supervisão clínica ou julgamento de um analista do comportamento. O uso proposto é de apoio à decisão e de priorização preventiva, sempre vinculado a planos previamente aprovados.

1. Resumo executivo dos achados

A literatura sobre previsão de comportamentos-problema em TEA e deficiências do desenvolvimento é promissora, porém ainda pequena, heterogênea e metodologicamente vulnerável. Uma revisão sistemática publicada em 2026 identificou 13 estudos com wearables, mas apenas cinco desenvolveram modelos preditivos propriamente ditos; três deles reutilizaram a mesma fonte de dados. A revisão também destacou risco de superestimação quando dados do mesmo participante aparecem simultaneamente nos conjuntos de treino e teste (Romani et al., 2026). Uma revisão narrativa de 2025 concluiu que modelos personalizados ou por subgrupos tendem a ser necessários, devido à grande heterogeneidade entre pessoas, topografias, funções e contextos (Ferina et al., 2025).

- **Evidência mais consistente para risco iminente:** regressão logística com biossensores e validação separando pessoas/sessões. Em 70 jovens autistas internados, o melhor modelo geral previu comportamento agressivo três minutos antes com AUROC médio de 0,80; a frequência recente do próprio comportamento acrescentou informação preditiva (Imbiriba et al., 2023).
- **Evidência mais transferível para a bHave:** modelos individualizados de próxima sessão/próximo dia usando histórico longitudinal, sono, condições médicas, ambiente e frequência recente (Cohen et al., 2018; Ferina et al., 2023; Kiarashi et al., 2024, 2025).
- **Maior risco metodológico:** confundir detecção com previsão; dividir linhas aleatoriamente em séries temporais; usar variáveis registradas após o início do episódio; selecionar o limiar no conjunto de teste; e reportar apenas acurácia em eventos raros.

- **Melhor estratégia inicial:** baselines simples, regressão logística regularizada e modelo de sobrevivência em tempo discreto; em seguida, CatBoost/LightGBM/XGBoost. Redes LSTM/GRU devem ser reservadas para bases densas, grandes e cuidadosamente validadas.
- **Métrica principal:** não há uma única métrica suficiente. Recomenda-se AUPRC e recall para eventos raros, AUROC como complemento, Brier score e curvas de calibração para probabilidades, além de falsos alertas por paciente-hora/sessão, antecedência útil e benefício líquido clínico.
- **Arquitetura de segurança:** API bHave → ingestão segura → pseudonimização → modelo de dados temporal → feature store → treino/registo/calibração → serviço de previsão → painel clínico → auditoria e monitoramento de drift.

Conclusão executiva

É tecnicamente plausível construir um MVP com dados já registrados na bHave, especialmente para horizontes de “restante da sessão”, “próxima sessão” e “próximo dia”. A viabilidade para previsão em minutos depende de timestamps precisos de início, registro de exposição ao contexto e densidade de observações negativas. A primeira meta do MVP deve ser demonstrar validade retrospectiva e prospectiva silenciosa, não disparar alertas clínicos imediatamente.

Síntese das respostas às perguntas centrais

Questão	Resposta sintética
Modelos promissores	Regressão logística regularizada e modelos hierárquicos como referência; sobrevivência em tempo discreto para risco por janela; CatBoost/boosting para não linearidades; Markov/estado para sequências; redes recorrentes apenas com grande volume.
Variáveis de maior valor	Frequência/recência do próprio comportamento, tempo desde o último episódio, tendências em múltiplas janelas, contexto/antecedente, transição de atividade, hora/dia, sono/rotina, exposição a demandas e intervenções. O valor é geralmente individual e não universal.
Variável-alvo	$y=1$ quando o primeiro início operacionalmente definido de X ocorre após o instante de decisão e dentro do horizonte H; $y=0$ quando há observação suficiente sem ocorrência. Episódios em curso devem ser excluídos ou modelados separadamente.
Melhor horizonte	Multi-horizonte. Começar com próxima sessão e próximo dia; incluir 15/30/60 min apenas se o timestamp e a cobertura da observação forem confiáveis. A janela deve permitir uma ação segura e previamente aprovada.
Desbalanceamento	Pesos de classe/custos, amostragem apenas no treino, avaliação por AUPRC e falsos alertas, limiares por utilidade, e comparação com prevalência/frequência recente. Evitar SMOTE ingênuo entre pacientes e tempos.
Interpretabilidade	Odds ratios/coeficientes para modelos lineares; SHAP e importância por permutação para boosting; explicações locais com aviso de associação, não causa; sempre mostrar baseline pessoal, qualidade do dado e incerteza.
Governança	LGPD, base legal documentada, minimização, pseudonimização, controle de acesso, registro de operações, avaliação ética/CEP-CONEP quando aplicável e análise regulatória de SaMD antes de uso clínico.

2. Tabela comparativa dos estudos selecionados

A relevância foi classificada para o projeto bHave, não como ranking absoluto de qualidade científica. “Alta” indica previsão futura diretamente transferível ou forte contribuição metodológica; “Média” indica associação, detecção ou amostra pequena com método aproveitável; “Baixa” indica aplicabilidade limitada ou informação metodológica insuficiente.

Estudo, título e DOI	Base/fonte	População e contexto	Dados e preditores	Variável-alvo e horizonte
Goodwin et al. (2019) Predicting aggression to others in youth with autism using a wearable biosensor DOI: 10.1002/aur.2151	Autism Research / PubMed / Wiley	20 jovens com TEA, 6–17 anos; unidade psiquiátrica de internação.	BVP, intervalo interbatimentos, EDA e aceleração; 180 s anteriores em bins de 15 s; tempo desde agressão.	Início de agressão a terceiros em 1 min.
Imbiriba et al. (2023) Wearable biosensing to predict imminent aggressive behavior in psychiatric inpatient youths with autism DOI: 10.1001/jamanetworkopen.2023.48898	JAMA Network Open	70 jovens com TEA, 5–19 anos, em 4 hospitais psiquiátricos; 429 sessões/497 h.	Cardiovascular, EDA, movimento e histórico recente; 6.665 eventos codificados.	SIB, desregulação emocional e agressão a terceiros em 1–3 min.
Cohen et al. (2018) Sleep patterns predictive of daytime challenging behavior in individuals with low-functioning autism DOI: 10.1002/aur.1899	Autism Research / PubMed / Wiley	67 residentes com TEA e altas necessidades de suporte; >20.000 pares noite–dia.	Duração, horário, regularidade e variabilidade do sono em até oito noites.	Agressão, autolesão, birras, destruição e índice combinado no dia seguinte.
Ferina et al. (2023) Predicting problematic behavior in ASD using medical history and environmental data DOI: 10.3390/jpm13101513	Journal of Personalized Medicine / PubMed	80 pessoas com TEA em serviço residencial; dados diários de 2015–2021.	Histórico de agressão/SIB, sintomas gastrointestinais, sono, condições médicas, ambiente/clima e intervenções.	Agressão, SIB ou ambos no dia seguinte.
Kiarashi et al. (2024) Off-body sleep analysis for predicting adverse behavior in individuals with ASD DOI: 10.1109/JBHI.2024.3455942	IEEE JBHI / PubMed	14 pessoas com TEA; >2.000 noites em dois anos.	Sono off-body por infravermelho próximo, arquitetura/fragmentação e histórico comportamental.	Agressão, SIB e interrupção no dia seguinte, manhã e tarde.
Kiarashi et al. (2025) Predicting seizure episodes and high-risk events in autism through adverse behavioral patterns DOI: 10.1088/1361-6579/adcafd	Physiological Measurement / PubMed	353 pessoas com autismo profundo; nove anos de registros longitudinais.	Sete categorias de comportamento e sequências históricas de 7/14 dias.	Evento no dia seguinte: crise epilética, agressão, SIB ou elopement.
Kim et al. (2026) Feasibility of forecasting self-injurious behavior among autistic youth using wearable sensors and ML DOI: 10.1038/s41598-026-50079-z	Scientific Reports / PubMed	9 jovens autistas; observação clínica com vídeo e dois wearables.	Aceleração, fisiologia, janelas de observação sem comportamento em curso.	SIB/comportamento-alvo futuro em horizontes de 3 a 120 s.
Zheng et al. (2021) A predictive multimodal framework to alert caregivers of problem behaviors for children with ASD (PreMAC) DOI: 10.3390/s21020370	Sensors / PubMed / IEEE-related	7 crianças com TEA, 4–15 anos; contexto controlado de PFA/IISCA.	E4, Kinect, roupa WINGS, postura/movimento, fisiologia, orientação social e expressões.	Precursores iminentes de comportamento-problema em 30–120 s.
Nuske et al. (2019) Heart rate increase predicts challenging behavior episodes in preschoolers with autism DOI: 10.1080/10253890.2019.1572744	Stress / PubMed / Taylor & Francis	41 pré-escolares recrutados; 13 apresentaram episódios analisáveis.	Frequência cardíaca e variabilidade antes/durante episódios.	Ocorrência de episódio desafiador; relação temporal pré-episódio.

Estudo, título e DOI	Base/fonte	População e contexto	Dados e preditores	Variável-alvo e horizonte
Alban et al. (2023) Heart rate as a predictor of challenging behaviours among children with autism from wearable sensors in social robot interactions DOI: 10.3390/robotics12020055	Robotics / MDPI	5 crianças com TEA em sessões com robô social/brinquedos.	FC, BVP, EDA, temperatura, aceleração e vídeo anotado.	Classes de comportamento durante a sessão; predominantemente detecção.
Cantin-Garside et al. (2020a) Detecting and classifying self-injurious behavior in ASD using ML techniques DOI: 10.1007/s10803-020-04463-x	JADD / PubMed / Springer	11 crianças com TEA e SIB; 24 topografias.	Acelerômetros corporais e anotações observacionais.	Detectar e distinguir SIB já ocorrendo.
Cantin-Garside et al. (2020b) Multi-level modeling with nonlinear movement metrics to classify self-injurious behaviors in ASD DOI: 10.1038/s41598-020-73155-4	Scientific Reports	10 participantes com TEA/SIB; >200 episódios e 18 tipos de SIB.	Aceleração, domínio de frequência, variabilidade linear e não linear.	Classificação de SIB contemporânea.
Khullar et al. (2021) Meltdown/tantrum detection system for individuals with ASD DOI: 10.1080/08839514.2021.1991115	Applied Artificial Intelligence / Taylor & Francis	População/amostra não suficientemente detalhada nas fontes acessíveis.	FC, temperatura e resposta galvânica da pele por pulseira.	Detecção de meltdown/tantrum.
Rad et al. (2025) From motion to emotion: exploring challenging behaviors in ASD through wearable physiology and movement DOI: 10.1088/1361-6579/ada51b	Physiological Measurement / PubMed	11 adolescentes do sexo masculino com TEA, 10–20 anos, em ambiente naturalístico.	EDA, temperatura da pele e aceleração; wavelet scattering.	Identificação de comportamentos desafiadores/SIB em curso.

Tabela 1A. Identificação, população, dados e alvo dos estudos selecionados.

Estudo	Modelo/método	Métricas	Principais resultados	Limitações críticas
Goodwin et al. (2019)	Regressão logística ridge; modelos populacional e individual.	AUROC; validação cruzada repetida.	AUROC 0,71 no modelo global e 0,84 no modelo individual. Combinação de movimento e fisiologia foi melhor.	Amostra pequena; validação global não garantiu independência entre participantes, com risco de vazamento.
Imbiriba et al. (2023)	Regressão logística, SVM, redes neurais e adaptação de domínio; modelos populacionais e individuais.	AUROC, IC95%; divisões por sessão, leave-individuals-out e leave-sessions-out.	Regressão logística mais consistente; AUROC médio 0,80 a 3 min. SIB foi mais previsível; intensidade alta teve melhor previsão.	Contexto de internação, seleção de quem tolerou o wearable, generalização para serviços ambulatoriais desconhecida.
Cohen et al. (2018)	SVM individualizado.	Significância individual e acurácia preditiva; comparação com permutações.	Relação preditiva significativa em 81% dos indivíduos; regularidade/variabilidade do sono foi central.	Residencial; modelos individualizados; detalhes de calibração e utilidade clínica limitados.
Ferina et al. (2023)	ADALINE/rede de uma camada com transformação de kernel; regressão logística benchmark; modelos individuais.	Balanced classification rate e repetição de divisões 85:15.	Desempenhos >80% em subconjunto de indivíduos; variáveis GI e ambientais frequentemente úteis; modelos populacionais fracos.	Divisão aleatória em série temporal; mudanças de tratamento, observadores e COVID; desbalanceamento pode favorecer baseline.
Kiarashi et al. (2024)	Ensemble de classificadores; modelos por indivíduo.	Acurácia, F1 e balanced accuracy.	Manhã mais previsível; acurácia/F1 alvo-específicas ~0,74; desempenho acima do acaso em 7/14.	Amostra pequena, heterogeneidade, métricas/calibração limitadas.
Kiarashi et al. (2025)	Modelo convolucional/autoregressivo profundo sobre padrões de eventos.	Acurácia e testes de permutação reportados.	Acurácia de 78,3% para agressão, 80,2% para SIB e 85,7% para elopement.	Acurácia isolada pode ser enganosa; calibração e prevalência por alvo não foram suficientes nas fontes acessíveis.

Estudo	Modelo/método	Métricas	Principais resultados	Limitações críticas
Kim et al. (2026)	Random Forest, AdaBoost.M2, LSTM e LSTM empilhada.	AUROC, AUPRC, precisão, recall, especificidade, F1, MCC; leave-one-subject-out.	Viabilidade acima do acaso, especialmente em horizontes mais longos; grande variabilidade entre pessoas; nenhum modelo dominou consistentemente.	n=9; alvo agregado; contexto clínico; janela histórica curta.
Zheng et al. (2021)	Random Forest, redes neurais e outros classificadores; perfis individuais e de grupo.	Acurácia por perfil/horizonte.	RF: 98,51% individual e 82,36% grupo; movimento do torso foi principal modalidade.	Amostra muito pequena, cenário contrived, oversampling; prevê precusores e não o comportamento final.
Nuske et al. (2019)	Análises estatísticas/ROC; não um pipeline preditivo completo.	AUROC e testes de associação.	Elevação de FC antes dos episódios; AUROC aproximada 0,72 para FC corrigida pelo baseline; HRV não consistente.	Poucos participantes com eventos; associação não equivale a validação prospectiva.
Alban et al. (2023)	XGBoost, árvore, MLP e SVM.	Acurácia, precisão, recall e F1.	XGBoost reportou acurácia 99%, F1 0,93; FC foi a variável mais importante.	n=5; detecção contemporânea; divisão aleatória e risco de vazamento/overfitting.
Cantin-Garside et al. (2020a)	KNN, SVM e classificadores comparativos.	Acurácia/classificação por episódio.	Desempenho alto de detecção (~92–93% nos melhores classificadores).	Não prevê futuro; amostra pequena e ambiente estruturado.
Cantin-Garside et al. (2020b)	Regressão logística multinível com PCA e efeitos individuais.	Acurácia e variância explicada.	>75% de acurácia e >65% da variância explicada; abordagem interpretável e hierárquica.	Detecção; n pequeno; resultado não demonstra antecipação.
Khullar et al. (2021)	Isolation Forest, CNN, LSTM e CNN-LSTM.	Acurácia reportada.	Acurácia de aproximadamente 96% reportada no artigo/revisões.	Detalhes de amostra, divisão e validação não foram verificáveis; detecção, não previsão futura robusta.
Rad et al. (2025)	LSTM e fusão de modalidades.	Sensibilidade, especificidade, F1 e AUROC.	Aceleração foi melhor: sens. 0,62, esp. 0,71, F1 0,36, AUROC 0,71; fisiologia isolada mais fraca.	Detecção, n pequeno, F1 modesto e amostra pouco diversa.

Tabela 1B. Métodos, avaliação, resultados e limitações.

Estudo	Relação com ABA/análise comportamental	Aplicabilidade à API/dados bHave	Relevância para o projeto
Goodwin et al. (2019)	Registro direto do comportamento; útil como alerta, mas sem inferência funcional.	Alta para desenho temporal e recursos de recência; sinais fisiológicos exigiriam integração futura.	Alta (com ressalva de validação)
Imbiriba et al. (2023)	Comportamentos operacionalizados e anotados ao vivo; não substitui análise funcional.	Muito alta para validação por pessoa/sessão, histórico recente e previsão multi-horizonte.	Alta
Cohen et al. (2018)	Demonstra evento estabelecedor/contextual longitudinal; não identifica função.	Alta se sono/rotina puderem ser registrados ou integrados.	Alta
Ferina et al. (2023)	Contexto e história são úteis, mas faltam variáveis funcionais e exposição detalhada.	Muito alta: estrutura tabular longitudinal próxima à API clínica.	Alta (risco de validação otimista)
Kiarashi et al. (2024)	Sono como setting event; deve ser combinado a contexto funcional.	Alta para próximo dia/próxima sessão; exige integração de sono.	Alta
Kiarashi et al. (2025)	História recente de topografias pode sinalizar estados de risco, sem estabelecer causa/função.	Muito alta para séries de eventos extraídas por API.	Alta
Kim et al. (2026)	Formulação rigorosa separa detecção de previsão; ainda não estima função.	Alta para definição de janelas e avaliação; sensores não são necessários no primeiro MVP.	Alta metodológica
Zheng et al. (2021)	Integra explicitamente PFA/IISCA e observação por BCBA; forte alinhamento conceitual.	Alta para modelos híbridos função-contexto; números de desempenho não devem ser extrapolados.	Alta conceitual / Média empírica
Nuske et al. (2019)	Possível marcador de ativação; função e antecedentes ambientais continuam essenciais.	Média; sugere integração futura de sensores.	Média

Estudo	Relação com ABA/análise comportamental	Aplicabilidade à API/dados bHave	Relevância para o projeto
Alban et al. (2023)	Pode automatizar registro, mas não representa previsão causal ou funcional.	Média para rotulagem e sensores; baixa para estimar desempenho futuro real.	Média/Baixa
Cantin-Garside et al. (2020a)	Útil para melhorar fidelidade e granularidade do registro de resposta.	Média para validação automática de eventos e qualidade do dado.	Média
Cantin-Garside et al. (2020b)	Modelos multinível respeitam repetição por paciente e topografia.	Alta para estrutura hierárquica; média para objetivo de previsão.	Média
Khullar et al. (2021)	Potencial alerta de desregulação, sem análise funcional.	Baixa/Média até haver replicação e transparência metodológica.	Baixa/Média
Rad et al. (2025)	Mostra valor do movimento como marcador de topografia; não estima função.	Média para futura integração de sensores e auditoria de eventos.	Média

Tabela 1C. Relação clínica, transferência para bHave e relevância.

ARTIGO ACADÊMICO

Modelos preditivos para antecipação de comportamentos-problema em Análise do Comportamento Aplicada: revisão crítica e proposta metodológica para dados da plataforma bHave

Resumo

Comportamentos-problema, incluindo agressão, autolesão, fuga, esquiva, destruição, crises e desregulação, podem apresentar baixa frequência, alta gravidade e forte dependência do contexto. A ampliação dos registros digitais em serviços de Análise do Comportamento Aplicada (ABA) cria a possibilidade de estimar risco futuro a partir de séries temporais clínicas. Este artigo revisa criticamente estudos que empregaram machine learning, modelos estatísticos, biossensores, sono, ambiente e históricos longitudinais para antecipar comportamentos desafiadores em autismo e deficiências do desenvolvimento. A literatura demonstra viabilidade inicial em horizontes de segundos a um dia, mas é limitada por amostras pequenas, validação inadequada, confusão entre detecção e previsão, heterogeneidade individual e pouca avaliação de calibração e utilidade clínica. São propostos um desenho de coorte retrospectiva e prospectiva, uma definição formal da variável-alvo, janelas multi-horizonte, engenharia de atributos compatível com a API da bHave e uma sequência de modelos que começa por baselines, regressão logística regularizada, modelos hierárquicos e sobrevivência em tempo discreto, seguida por gradient boosting. Recomenda-se validação temporal e por paciente, métricas adequadas a eventos raros, explicabilidade, monitoramento de drift e validação clínica silenciosa. A arquitetura conceitual inclui ingestão segura, pseudonimização, modelo canônico de eventos, feature store, registro de modelos, serviço de previsão, painel clínico e auditoria. O sistema deve apresentar risco calibrado, baseline pessoal, qualidade do dado e fatores associados, sem inferir função causal ou substituir avaliação funcional e julgamento clínico. São discutidas exigências éticas, LGPD, pesquisa com bases de dados e possível enquadramento como software como dispositivo médico.

Palavras-chave: análise do comportamento aplicada; autismo; comportamento-problema; machine learning; modelos preditivos; séries temporais; saúde digital; explicabilidade.

Abstract

Problem and challenging behaviors—including aggression, self-injury, elopement, avoidance, property destruction, crises, and emotional dysregulation—may be infrequent, severe, and highly context-dependent. The increasing availability of digital records in Applied Behavior Analysis (ABA) services creates an opportunity to estimate future risk from clinical time series. This article critically reviews machine-learning and statistical studies using biosensors, sleep, environmental information, and longitudinal histories to forecast challenging behaviors in autism and developmental disabilities. Evidence supports initial feasibility from seconds to one day ahead, but remains constrained by small samples, flawed validation, confusion between detection and forecasting, person-level heterogeneity, and limited assessment of calibration and clinical utility. We propose a retrospective and prospective cohort design, formal target definition, multi-horizon prediction, feature engineering aligned with the bHave API, and a modeling sequence beginning with simple baselines, regularized logistic regression, hierarchical models, and discrete-time survival, followed by gradient boosting. Temporal and patient-level validation, rare-event metrics, explainability, drift monitoring, and prospective silent validation are recommended. The system should display calibrated absolute risk, personal baseline, data-quality

indicators, and associated factors, while avoiding causal or functional claims and never replacing functional assessment or clinical judgment.

Keywords: applied behavior analysis; autism; challenging behavior; machine learning; predictive modeling; time series; digital health; explainable AI.

1. Introdução

A Análise do Comportamento Aplicada organiza a avaliação e a intervenção sobre relações funcionais entre comportamento e ambiente. Em casos de agressão, autolesão, fuga, destruição ou crises, a prioridade clínica é definir topografias observáveis, medir a resposta com confiabilidade, identificar variáveis relevantes e selecionar intervenções baseadas em função. A análise funcional experimental continua sendo o método mais forte para demonstrar relações funcionais; a previsão estatística, por sua vez, procura responder a uma pergunta diferente: dadas as informações disponíveis até um instante t , qual é a probabilidade de um evento ocorrer após t dentro de uma janela definida? Essas duas perguntas são complementares, mas não intercambiáveis (Iwata et al., 1994; Romani et al., 2026).

A digitalização de registros clínicos torna possível agregar eventos, sessões, antecedentes, consequências, hipóteses funcionais, estratégias, intensidade, duração, desempenho em programas, prompts, independência, terapia, ambiente e horário. Uma API como a da bHave pode converter esses registros em uma série temporal estruturada. O desafio não é apenas selecionar um algoritmo: é construir um alvo temporal sem vazamento, assegurar que os períodos sem comportamento representem observação real, separar pacientes e tempos entre treino e teste, calibrar probabilidades e definir como um alerta poderia melhorar uma decisão clínica sem gerar coerção, estigma ou substituição do profissional.

Os estudos existentes cobrem dois extremos. De um lado, wearables coletam fisiologia e movimento a cada segundo para prever ou detectar episódios iminentes. De outro, bases residenciais e clínicas agregam sono, saúde, ambiente e histórico comportamental para prever o dia seguinte. Entre esses extremos encontra-se o espaço mais relevante para a bHave: risco durante a sessão, restante da sessão, próxima sessão ou próximo dia, usando dados clínicos já registrados. A viabilidade desse espaço depende da qualidade temporal e semântica dos registros.

2. Justificativa

Uma ferramenta de previsão pode apoiar preparação de equipe, organização de ambiente, revisão de demandas, disponibilidade de comunicação funcional, escolha de reforçadores, checagem de sono ou saúde, e aplicação mais consistente de estratégias já aprovadas. O benefício potencial é maior quando o comportamento tem alta gravidade e quando existe uma ação preventiva de baixo risco e compatível com o plano terapêutico. Entretanto, a mesma ferramenta pode causar dano caso o risco seja tratado como certeza, caso produza vigilância excessiva ou caso leve a redução de oportunidades, restrição preventiva, rotulação do paciente ou responsabilização indevida de terapeutas.

Do ponto de vista científico, a plataforma bHave oferece uma oportunidade de aproximar ciência de dados e análise comportamental em dados de mundo real. Ela permite avaliar se variáveis funcionais e contextuais acrescentam valor além de baselines simples, se modelos individuais são superiores aos populacionais e se probabilidades calibradas mantêm desempenho em diferentes serviços, profissionais e períodos. A contribuição esperada não é “adivinhar o comportamento”, mas quantificar incerteza de forma auditável e clinicamente útil.

3. Problema de pesquisa

Pergunta principal

Em pacientes atendidos em serviços de ABA, registros clínicos e comportamentais disponíveis até um instante de decisão permitem estimar, com discriminação, calibração e utilidade clínica aceitáveis, a probabilidade de um comportamento X ocorrer em uma janela futura, além do desempenho de baselines baseados em prevalência pessoal e frequência recente?

Perguntas secundárias incluem: (a) quais horizontes apresentam melhor relação entre desempenho e tempo útil de intervenção; (b) quanto o modelo se beneficia de antecedentes, contexto, hipótese funcional, intervenção e desempenho em programas; (c) quando um modelo populacional, hierárquico ou personalizado é mais adequado; e (d) como o desempenho varia por paciente, topografia, função, serviço e qualidade do registro.

4. Objetivos

4.1 Objetivo geral

Desenvolver e validar uma metodologia de previsão probabilística de comportamentos-problema a partir de dados longitudinais extraídos da API da bHave, para apoio à tomada de decisão clínica em ABA, sem substituir avaliação funcional ou julgamento profissional.

4.2 Objetivos específicos

- Construir um modelo canônico de eventos, sessões, ABC, programas, prompts, intervenções, profissionais e contexto.
- Definir operacionalmente o comportamento X e alvos temporais reproduzíveis para múltiplos horizontes.
- Comparar baselines simples com regressão logística, modelos hierárquicos, sobrevivência, árvores e boosting.
- Avaliar discriminação, calibração, antecedência útil, falsos alertas e benefício clínico.
- Quantificar heterogeneidade entre pacientes e testar personalização responsável.
- Desenvolver explicações compreensíveis e não causais para analistas do comportamento.
- Validar prospectivamente o modelo em modo silencioso antes de qualquer alerta operacional.
- Implementar governança de dados, privacidade, segurança, auditoria e monitoramento de drift.

5. Método da revisão de literatura

Foi realizada uma revisão estruturada narrativa com busca atualizada até 13 de julho de 2026. Foram usadas combinações em inglês e português envolvendo behavior prediction, challenging behavior, problem behavior, applied behavior analysis, ABC data, time series, autism, aggression, self-injury, digital phenotyping, ecological momentary assessment, machine learning, predictive analytics e equivalentes em português. As fontes prioritárias foram PubMed, Google Scholar, periódicos das editoras Springer Nature, Wiley, Taylor & Francis, Elsevier/ScienceDirect, IEEE, ACM, JAMA Network e periódicos revisados por pares. Foram consultadas referências de revisões recentes para busca em cadeia.

Foram incluídos estudos com estimativa futura, risco, padrões temporais, classificação ou detecção relevante para construção de um sistema preditivo, desde que descrevessem dados e método. Foram excluídas fontes comerciais, blogs, textos exclusivamente conceituais e trabalhos sem relação com modelagem ou previsão. Estudos de detecção foram mantidos apenas quando forneciam métodos úteis para melhorar a medição, a rotulagem ou a engenharia de atributos. Não foi realizado protocolo PRISMA, registro PROSPERO, dupla triagem independente ou busca autenticada exaustiva no Scopus; portanto, as conclusões devem ser interpretadas como revisão crítica aplicada, não meta-análise.

6. Revisão de literatura

6.1 Estado geral da evidência

A revisão narrativa de Ferina et al. (2025) descreve estratégias que variam de predição iminente a previsão de um dia, mas ressalta que poucos estudos possuem populações grandes e diversas. A revisão sistemática de Romani et al. (2026) é ainda mais cautelosa: entre 13 estudos com wearables, somente cinco usaram modelos que permitiam avaliar genuinamente a relação preditiva, e três reutilizaram a mesma base. Esse achado reduz a aparente quantidade de replicações independentes e mostra que “relação fisiológica antes do evento” não é sinônimo de desempenho preditivo validado.

A heterogeneidade é uma característica central. Comportamentos com a mesma topografia podem ter funções distintas; a mesma pessoa pode variar por rotina, intervenção, privação, saúde, sono, equipe e contexto; pessoas diferentes podem ter precursores incompatíveis. Por isso, modelos individuais frequentemente superam modelos globais, como observado em Goodwin et al. (2019), Cohen et al. (2018) e Ferina et al. (2023). Para a bHave, isso sugere arquitetura hierárquica: aprender padrões compartilhados sem apagar parâmetros individuais.

6.2 Previsão iminente com fisiologia e movimento

Goodwin et al. (2019) usaram três minutos de sinais fisiológicos e de movimento para estimar agressão a terceiros no minuto seguinte. O modelo individual atingiu AUROC 0,84, contra 0,71 no modelo global. A revisão de Romani et al. (2026), entretanto, observou que a validação do modelo global permitia dados do mesmo participante em treino e teste, o que pode inflar a generalização. Esse ponto é decisivo para estudos clínicos: a unidade de independência não é a linha da tabela, mas o paciente e o período temporal.

Imbiriba et al. (2023) ampliaram o estudo para 70 jovens, 4 hospitais, 497 horas e 6.665 eventos. A regressão logística foi mais consistente que modelos mais complexos e atingiu AUROC médio de 0,80 para previsão três minutos antes. A validação incluiu separação por indivíduos e sessões. O histórico recente do comportamento aumentou o desempenho, e episódios de maior intensidade foram mais previsíveis. Esse resultado sustenta três decisões para a bHave: incluir recursos de recência, testar modelos simples antes de redes neurais e estratificar desempenho por topografia/intensidade.

O estudo de Kim et al. (2026) contribuiu ao separar explicitamente janelas de observação sem comportamento em curso das janelas futuras. Essa formulação evita que o modelo simplesmente reconheça o início do evento. Com apenas nove participantes, houve grande variabilidade e nenhum algoritmo dominou consistentemente; horizontes mais longos tiveram maior AUPRC. O resultado reforça que previsão de segundos é difícil e que um horizonte maior pode ser mais robusto, embora menos específico para uma ação imediata.

6.3 Sono, saúde, ambiente e previsão do dia seguinte

Cohen et al. (2018) analisaram mais de 20 mil noites em 67 residentes. Modelos SVM individualizados encontraram relação significativa entre sono e comportamento diurno em 81% dos indivíduos; a regularidade do sono foi mais importante do que uma medida isolada de duração. Kiarashi et al. (2024) utilizaram análise off-body e encontraram desempenho moderado para agressão, SIB e interrupção no dia seguinte, com melhor previsibilidade na manhã. Esses achados tratam o sono como variável contextual ou setting event, não como explicação funcional completa.

Ferina et al. (2023) integraram dados médicos, gastrointestinais, ambientais e históricos para prever agressão/SIB no dia seguinte em 80 pessoas. Modelos individuais foram superiores aos populacionais; sintomas gastrointestinais e ambiente apareceram como preditores em parte dos indivíduos. Contudo, a divisão aleatória 85:15 em uma série temporal e a forte assimetria de classes podem produzir estimativas otimistas. Um baseline de prevalência histórica poderia superar o modelo em pacientes com alta predominância de uma classe, demonstrando por que comparação com regras simples é obrigatória.

Kiarashi et al. (2025) modelaram nove anos de registros de 353 pessoas e mostraram que sequências recentes de comportamentos adversos contêm informação sobre eventos no dia seguinte. O estudo é particularmente relevante porque trabalha com registros longitudinais semelhantes aos que uma API clínica pode fornecer. Ainda assim, acurácia sem prevalência, calibração e falsos alertas não é suficiente para decidir uso clínico.

6.4 Detecção, classificação e precursores

Estudos como Cantin-Garside et al. (2020a, 2020b), Alban et al. (2023), Khullar et al. (2021) e Rad et al. (2025) classificaram comportamento em curso a partir de movimento e fisiologia. Esses trabalhos são relevantes para automatizar medição e melhorar o ground truth, mas não demonstram que o evento possa ser antecipado. Métricas muito altas em amostras pequenas podem refletir assinatura motora do episódio, pessoa específica, sessão específica ou vazamento temporal.

Zheng et al. (2021) são um caso intermediário: o PreMAC prevê precursores definidos em um contexto de avaliação prática funcional/IISCA, e não necessariamente o comportamento perigoso. O estudo integra tecnologia e análise comportamental de modo conceitualmente forte, mas os valores de acurácia não devem ser extrapolados devido à amostra de sete crianças, ao contexto controlado e à provável dependência entre janelas. Para a bHave, a principal lição é registrar precursores operacionalizados e a sequência de estados, não reproduzir diretamente a acurácia reportada.

6.5 Distinção entre previsão, associação, detecção e causalidade

- **Associação temporal:** uma variável muda antes do comportamento, mas o estudo não mostra desempenho fora da amostra.
- **Detecção:** o algoritmo identifica um comportamento já iniciado, muitas vezes pela própria assinatura motora.
- **Previsão:** o conjunto de entrada termina antes do início do evento e o desempenho é avaliado em tempos/pessoas não usados no treino.
- **Estimativa causal/funcional:** requer desenho que identifique efeito de uma variável ou contingência; a importância de uma feature não demonstra função.

Um sistema bHave deve declarar explicitamente qual dessas tarefas realiza. A interface não deve chamar de “causa” ou “função” uma variável associada ao risco. Mesmo a hipótese funcional registrada é uma informação clínica produzida por avaliação, e sua contribuição ao modelo deve ser interpretada como estratificação, não confirmação algorítmica.

7. Discussão crítica

7.1 Quais modelos parecem mais promissores?

A regressão logística regularizada é o melhor primeiro modelo para classificação por janela: é estável, interpretável, permite probabilidades e teve desempenho competitivo em dados de biossensores (Goodwin et al., 2019; Imbiriba et al., 2023). Para dados repetidos por paciente e serviço, a extensão natural é regressão logística hierárquica/multinível, com interceptos e, quando sustentado pelos dados, inclinações aleatórias. Isso permite combinar informação populacional com personalização parcial.

Quando o interesse é “quando ocorrerá o primeiro episódio?”, modelos de sobrevivência em tempo discreto são especialmente adequados, pois tratam censura, exposição desigual e risco variável ao longo do tempo. Regressão complementar log-log, Cox com covariáveis dependentes do tempo e modelos paramétricos flexíveis devem ser comparados. Para relações não lineares e interações, CatBoost, LightGBM ou XGBoost são candidatos fortes; CatBoost é atrativo para categorias de alta cardinalidade e valores ausentes, desde que identificadores de paciente/terapeuta não funcionem como atalhos de memorização.

Random Forest oferece baseline não linear e robusto, mas pode produzir probabilidades mal calibradas. Modelos bayesianos hierárquicos permitem incorporar incerteza e conhecimento prévio clínico, especialmente com poucos eventos por pessoa. Cadeias de Markov, HMM e modelos de estado são úteis quando há estados/precusores ordenados. ARIMA/SARIMA só é apropriado para contagens agregadas em intervalos regulares e não deve ser a primeira escolha para eventos esparsos por paciente. LSTM/GRU/TCN exigem grande volume sequencial, validação externa e comparação honesta com modelos simples.

7.2 Quais variáveis costumam ter maior valor preditivo?

O preditor mais consistente é o próprio histórico recente: número de episódios em janelas, taxa por tempo observado, tempo desde o último evento, intensidade recente, tendência e aglomeração. Sinais fisiológicos e movimento são úteis em segundos/minutos, enquanto sono, rotina, saúde e ambiente são úteis em horizontes de horas/dias. Na bHave, antecedentes, atividade/transição, demanda, disponibilidade de atenção ou item, ambiente, terapeuta, horário, função hipotetizada, exposição a intervenções e desempenho em programas podem acrescentar informação.

O valor preditivo não deve ser tratado como universal. “Terapeuta” pode representar diferenças de registro, horários, casos atribuídos ou implementação; “função hipotetizada” pode refletir qualidade da avaliação; “prompt” pode ocorrer após sinais de dificuldade. A engenharia de atributos deve distinguir exposição anterior ao instante de decisão de informação registrada como consequência do próprio evento.

7.3 Que dados são necessários?

- Timestamp preciso de início e, quando possível, término do comportamento X.
- Definição operacional versionada e identificador de topografia.
- Intervalos reais de observação/exposição, inclusive períodos sem evento.
- Identificador pseudônimo do paciente, sessão, serviço e aplicador.
- Antecedente/contexto e atividade vigentes antes do evento.
- Intervenções disponíveis/aplicadas antes do evento e adesão ao plano.
- Histórico de eventos, intensidade, duração e tempo desde o último episódio.

- Qualidade do registro, missingness, atraso de entrada e concordância entre observadores quando disponível.
- Dados de sono, saúde, medicação e rotina apenas quando há base clínica/legal, definição padronizada e benefício esperado.

7.4 Como transformar a bHave em base de machine learning?

O dado deve ser convertido de registros transacionais para uma tabela de “landmarks” ou instantes de decisão. Cada linha representa paciente i no instante t , contém apenas informações disponíveis até t e recebe um rótulo sobre a ocorrência em $(t, t+H]$. Essa transformação exige uma tabela de eventos com onset, uma tabela de sessões com intervalos de observação, uma tabela de contexto com validade temporal e uma tabela de intervenções/programas com início, fim e versão.

A extração deve preservar uma zona bruta imutável, depois normalizar fusos horários, tipos, categorias e versões. Identificadores diretos devem ser removidos antes da camada analítica. A tabela de features deve ser reproduzível por código versionado, com “as-of joins”: qualquer valor associado a um momento posterior não pode ser retroativamente incluído.

7.5 Como definir a variável-alvo?

Definição recomendada

Para paciente i , instante de decisão t e horizonte H : $y(i,t,H)=1$ se o primeiro início do comportamento X ocorrer no intervalo aberto $(t, t+H]$; $y=0$ se o paciente permanecer observado durante o horizonte e X não ocorrer. Janelas sem cobertura suficiente devem ser censuradas ou excluídas, não tratadas automaticamente como negativas.

Episódios em curso no instante t devem ser excluídos da tarefa de onset ou tratados em um modelo separado de duração/continuação. Após um evento, recomenda-se um período refratário/cooldown para evitar dezenas de linhas positivas referentes ao mesmo episódio. Para comportamentos repetitivos, pode ser adequado definir um novo episódio após um intervalo sem resposta predefinido clinicamente.

7.6 Qual janela de previsão?

Não existe uma janela universalmente melhor. O horizonte deve ser curto o suficiente para preservar especificidade e longo o suficiente para permitir ação. Recomenda-se desenvolvimento multi-horizonte: 15, 30 e 60 minutos; restante da sessão; próxima sessão; e próximo dia. O MVP pode começar com próxima sessão e próximo dia, porque exigem menor densidade temporal. Caso os dados tenham onsets precisos e observação contínua, 15/30/60 minutos podem ser adicionados.

O desempenho de horizontes não deve ser comparado apenas pela AUROC. Uma janela maior aumenta a prevalência do evento e pode melhorar métricas sem necessariamente oferecer melhor intervenção. Devem ser avaliados antecedência mediana, proporção de eventos alertados com tempo útil, falsos alertas por hora/sessão e aceitabilidade da ação preventiva.

7.7 Quais métricas são adequadas?

- **Discriminação:** AUROC e, principalmente em eventos raros, AUPRC. A AUPRC deve ser interpretada em relação à prevalência do teste (Saito & Rehmsmeier, 2015).
- **Classificação no limiar:** recall/sensibilidade, precisão/PPV, especificidade, F1 e matriz de confusão. O limiar deve ser definido no conjunto de validação por utilidade clínica.

- **Probabilidade:** Brier score, log loss, gráfico de calibração, intercepto e inclinação de calibração. Boa discriminação não garante que “30%” signifique 30% (Van Calster et al., 2019).
- **Operação:** falsos alertas por paciente-hora ou sessão, alertas por dia, tempo de antecedência, duração do estado de alerta e taxa de abstenção por dado insuficiente.
- **Utilidade:** decision-curve/net benefit, impacto em decisões, tratamento íntegro, eventos evitados e possíveis danos.
- **Incerteza:** intervalos de confiança por bootstrap agrupado por paciente e resultados por subgrupo.

7.8 Como lidar com dados desbalanceados?

A prevalência baixa torna acurácia particularmente inadequada. Estratégias recomendadas incluem pesos de classe ou custos, focal loss em redes, undersampling controlado dentro do treino e seleção de limiar conforme custo de falso negativo e falso positivo. O conjunto de validação e teste deve manter a prevalência real. SMOTE deve ser usado com extrema cautela; interpolar registros de pacientes ou tempos diferentes pode criar exemplos biologicamente e comportamentalmente incoerentes.

Também é importante modelar exposição. Um paciente com poucas horas observadas não deve ter a mesma interpretação de “zero eventos” que outro com observação contínua. Taxas, offsets e modelos de sobrevivência/contagem ajudam a corrigir essa diferença. O baseline de frequência recente e o de prevalência pessoal são competidores obrigatórios.

7.9 Como evitar interpretações equivocadas e garantir interpretabilidade?

Modelos lineares devem reportar coeficientes ou odds ratios, intervalos e transformações. Para boosting, SHAP pode descrever contribuições locais e globais, mas não demonstra causalidade (Lundberg & Lee, 2017). Importância por permutação deve ser calculada em folds independentes. Dependência parcial/ALE pode explorar relações não lineares, mas deve respeitar correlação entre variáveis.

O painel clínico deve apresentar: risco absoluto; baseline pessoal; horizonte; data/hora; versão do modelo; qualidade e cobertura dos dados; principais fatores associados; incerteza; e indicação de que o resultado não é análise funcional. O sistema não deve recomendar novas intervenções automaticamente. Deve apontar apenas para opções previamente definidas no plano e aprovadas pelo responsável clínico.

8. Proposta metodológica aplicada à bHave

8.1 Hipótese

Modelos que combinam histórico recente do comportamento, contexto antecedente, características da sessão e exposição a estratégias produzirão melhor discriminação e calibração do que baselines de prevalência e frequência recente, com benefício adicional de modelos hierárquicos ou personalizados para pacientes com histórico suficiente.

8.2 Tipo de estudo e desenho

Propõe-se uma coorte retrospectiva longitudinal multicêntrica para desenvolvimento e validação temporal, seguida de coorte prospectiva silenciosa. Na fase retrospectiva, os dados históricos são extraídos sem alterar o atendimento. Na fase prospectiva silenciosa, previsões são calculadas e armazenadas, mas não exibidas aos terapeutas; isso permite avaliar drift, atraso de dados e

desempenho real sem efeitos de reatividade. Somente após critérios pré-especificados e revisão ética/clínica deve ocorrer piloto de decisão assistida.

8.3 População-alvo

Pacientes com TEA, deficiência intelectual ou transtornos do desenvolvimento atendidos em serviços que utilizam a bHave, com definição estável do comportamento X, sessões documentadas e quantidade mínima de exposição. O primeiro estudo deve restringir uma topografia e um contexto suficientemente homogêneos, por exemplo agressão física ou autolesão em programas intensivos, em vez de agrupar qualquer “comportamento-problema”.

8.4 Critérios de inclusão dos dados

- Definição operacional do comportamento e unidade de registro disponíveis e versionadas.
- Timestamps de sessão e evento compatíveis com o horizonte analisado.
- Mínimo pré-especificado de horas/sessões e número de eventos por paciente para personalização.
- Períodos negativos com cobertura observacional confirmada.
- Plano/intervenção e contexto registrados antes do instante de decisão quando usados como features.
- Base legal, governança e aprovação ética aplicáveis documentadas.

8.5 Critérios de exclusão

- Registros duplicados, inconsistentes ou com timestamp impossível.
- Mudança substancial de definição operacional sem mapeamento/versionamento.
- Sessões sem tempo de exposição ou com grande atraso de registro incompatível com o uso pretendido.
- Variáveis derivadas após o evento ou do resumo final da sessão em previsão intrassessão.
- Períodos em que o comportamento já estava em curso para tarefa de onset.
- Pacientes/serviços com volume insuficiente para a análise proposta; estes podem permanecer em análise exploratória e não no teste principal.

8.6 Unidade de análise e janelas

Unidade principal: paciente × instante landmark. Para previsão intrassessão, landmarks podem ser criados a cada 5 ou 15 minutos, desde que haja observação contínua. Para previsão de sessão, o landmark é o início da sessão e o alvo é qualquer onset durante a sessão ou em um intervalo inicial. Para próxima sessão, o landmark é o encerramento da sessão atual. Para próximo dia, o landmark é um horário fixo ou o fechamento do dia clínico.

Lookbacks recomendados incluem 15/30/60 minutos, 1/3/7 sessões e 1/3/7/14 dias. Features em múltiplas escalas permitem distinguir pico agudo de tendência basal. Para cada horizonte, deve existir dataset e avaliação próprios.

8.7 Variáveis independentes possíveis

- **História de X:** contagem/taxa por janela, tempo desde último evento, intensidade/duração recentes, tendência, EWMA, burstiness, sequência de topografias.
- **Contexto:** ambiente, atividade, demanda, transição, disponibilidade de atenção/item, grupo/individual, ruído e horário.
- **ABC e função:** categorias de antecedentes anteriores, hipótese funcional, confiabilidade/versão da avaliação, consequências históricas apenas como contexto passado.

- **Sessão/equipe:** tipo e duração planejada, aplicador, supervisão, número de pessoas, mudança de terapeuta, dia da semana.
- **Intervenção:** plano vigente, estratégia previamente aplicada, integridade, disponibilidade de FCR, reforço, prompting e enriquecimento antecedente.
- **Aprendizagem/desempenho:** independência, erros, prompts, latência e tendência em programas, quando registrados antes do landmark.
- **Saúde/rotina:** sono, dor, sintomas GI, medicação, doença e eventos de rotina, somente com justificativa clínica e governança.
- **Qualidade:** missingness, atraso de entrada, densidade de registro, mudança de definição, observador e concordância.

8.8 Variáveis dependentes alternativas

- Binária: ocorrência de X no horizonte H.
- Tempo até primeiro onset: sobrevivência.
- Contagem de eventos: Poisson/negative binomial ou modelo hurdle/zero-inflated.
- Duração total no horizonte: regressão contínua ou modelo em duas partes.
- Intensidade/severidade: ordinal, desde que haja confiabilidade de mensuração.
- Multirrisco: agressão, SIB, fuga e desregulação separadas, evitando uma classe genérica quando possível.

8.9 Extração via API

1. Criar inventário de endpoints, dicionário de campos, chaves, fusos, paginação, limites e histórico de mudanças da API.
2. Executar carga inicial criptografada para uma zona bruta imutável e cargas incrementais por `updated_at/event_id`.
3. Validar esquema, unicidade, integridade referencial, intervalos temporais e categorias desconhecidas.
4. Pseudonimizar o paciente antes da camada analítica; manter o mapa de reidentificação em cofre separado e com acesso restrito.
5. Normalizar eventos, sessões, ABC, programas, intervenções e profissionais em tabelas temporais.
6. Construir features por código versionado, com joins “as of” e testes automáticos de vazamento.
7. Registrar lineage: versão da API, data da extração, filtros, transformações, versão da definição operacional e checksum.

8.10 Anonimização, pseudonimização e segurança

Pseudonimização é mais realista do que anonimização para um sistema longitudinal que precisa vincular sessões do mesmo paciente. Como os dados continuam reidentificáveis por uma chave, permanecem sujeitos à LGPD. Devem ser removidos nome, CPF, contato, endereço e texto livre desnecessário; datas podem ser preservadas apenas quando indispensáveis, ou deslocadas de forma consistente em conjuntos para pesquisa. Textos clínicos exigem desidentificação específica.

- Criptografia em trânsito e repouso; segregação de ambientes e chaves.
- Controle de acesso baseado em função, menor privilégio, MFA e revisão periódica.
- Logs imutáveis de acesso, extração, treino, previsão e visualização.
- Política de retenção, descarte seguro, backup e resposta a incidentes.
- Avaliação de impacto/RIPD quando apropriado e contratos com operadores/suboperadores.

- Proibição de uso secundário para punição, ranking de profissionais ou restrição de atendimento sem governança específica.

8.11 Limpeza e pré-processamento

- Deduplicar por evento e resolver sobreposições/episódios.
- Converter categorias para ontologia estável e mapear versões antigas.
- Quantificar missingness por paciente, profissional, serviço e tempo.
- Não imputar eventos ausentes como “zero”; distinguir não ocorrência de não observação.
- Imputar covariáveis apenas dentro do fold de treino, com indicador de ausência quando clinicamente justificável.
- Padronizar variáveis contínuas usando estatísticas do treino; preservar categorias raras em grupo “outro” sem esconder disparidades.
- Detectar mudanças de distribuição e entrada retroativa.

8.12 Engenharia de atributos

As features devem ser simples, auditáveis e alinhadas à lógica temporal. Exemplos: contagem de X nos últimos 15/60 minutos; taxa nos últimos 3/7 dias dividida por tempo observado; tempo desde o último onset; máximo de intensidade recente; inclinação da taxa; número de transições; proporção de tentativas independentes; variação de prompts; ocorrência histórica em mesmo ambiente/atividade/horário; interação entre função hipotetizada e antecedente vigente; mudança de terapeuta; e tempo desde alteração do plano.

Atributos de “paciente” e “terapeuta” exigem cuidado. O identificador bruto pode permitir memorização, dificultar novos pacientes e criar inferências injustas. Modelos hierárquicos, embeddings com regularização ou estatísticas históricas calculadas somente no treino são opções mais seguras. O desempenho deve ser testado em pacientes e profissionais não vistos.

8.13 Modelos candidatos e sequência de testes

Modelo	Uso proposto	Observação
Baseline 0	Prevalência pessoal/global por horizonte	Demonstra ganho mínimo necessário.
Baseline 1	Frequência recente, tempo desde último evento e regra clínica	Alta interpretabilidade; pode ser difícil de superar.
Regressão logística elastic net	Classificação por janela	Probabilidade, coeficientes e regularização.
GLMM/bayesiano hierárquico	Efeitos por paciente, serviço e terapeuta	Personalização parcial e incerteza.
Sobrevivência em tempo discreto	Hazard por intervalo, censura e covariáveis temporais	Formulação natural do risco de onset.
Random Forest	Baseline não linear	Robusto; calibrar posteriormente.
CatBoost/LightGBM/XGBoost	Não linearidades e interações	Candidato forte para dados tabulares; exige explicabilidade e calibração.
Markov/HMM/estado-espaco	Sequências de estados/precusores	Útil para transições, mas requer estados confiáveis.
ARIMA/SARIMA	Contagens agregadas regulares	Somente para nível de serviço/dia; limitado para evento individual esparsos.
LSTM/GRU/TCN	Sequências densas e grande amostra	Etapa tardia; risco de overfitting e baixa interpretabilidade.
Híbrido estatístico-comportamental	Interações/priors informados por função e contexto	Promissor se não converter hipótese clínica em verdade algorítmica.

8.14 Treino, validação e teste

A divisão principal deve ser temporal: período antigo para treino, período intermediário para validação/calibração e período mais recente para teste final. Dentro do desenvolvimento, usar validação cruzada agrupada por paciente e, quando necessário, por serviço. Para generalização a novos pacientes, usar leave-one-patient-out ou GroupKFold; para personalização, avaliar o modelo após um período mínimo de warm-up, sem usar o futuro do paciente.

Hiperparâmetros devem ser selecionados em validação interna/nested CV. O conjunto de teste deve ser tocado uma única vez. Intervalos de confiança devem usar bootstrap por paciente, não por linha. Deve haver validação externa em outro serviço/período e revalidação prospectiva silenciosa. O relato deve seguir TRIPOD+AI e o risco de viés pode ser avaliado com PROBAST+AI (Collins et al., 2024; Moons et al., 2025).

8.15 Explicabilidade

- Coeficientes padronizados, odds ratios e efeitos aleatórios para modelos lineares/hierárquicos.
- SHAP global e local para boosting, acompanhado de aviso de associação e análise de estabilidade entre folds.
- Importância por permutação em dados de teste e comparação com features correlacionadas.
- Curvas de calibração por paciente/subgrupo e exemplos de previsões corretas e incorretas.
- Model card com população, alvo, horizonte, dados, exclusões, métricas, limitações, fairness, drift e uso proibido.
- Regras de abstenção quando a qualidade/volume do dado está fora do domínio de treino.

8.16 Validação clínica com analistas do comportamento

8. Painéis com BCBA's para validar definição operacional, landmarks, features disponíveis no momento da decisão e ações possíveis.
9. Revisão cega de falsos positivos e falsos negativos, procurando erro de registro, mudança de plano, evento de saúde e confusão de topografia.
10. Estudo de concordância entre observadores em amostra de sessões e auditoria de timestamps.
11. Fase prospectiva silenciosa para medir desempenho real e drift sem alterar o tratamento.
12. Simulação de limiares: quantos alertas/dia, eventos capturados, tempo de antecedência e carga sobre a equipe.
13. Piloto controlado apenas com respostas preventivas de baixo risco, pré-aprovadas e registradas; avaliação de aceitabilidade, fidelidade e possíveis danos.

8.17 Riscos metodológicos e limitações esperadas

- Evento raro, heterogeneidade e poucos episódios por paciente.
- Variação de observadores, critérios de intensidade e atraso de entrada.
- Mudança de plano/medicação/rotina, criando concept drift.
- Confusão entre frequência do registro e frequência real do comportamento.
- Intervenções reativas que aparecem como preditores mas são consequência de sinais já percebidos.
- Generalização limitada entre serviços, faixas etárias e níveis de comunicação.
- Efeito performativo: quando o alerta muda o ambiente, a relação aprendida também muda.
- Risco de alert fatigue, estigma e redução indevida de oportunidades.
- Explicações de feature importance interpretadas como função ou causa.

9. Arquitetura conceitual do aplicativo preditivo

Arquitetura conceitual do aplicativo preditivo bHave




Figura 1. Fluxo conceitual da API bHave ao painel clínico e ao monitoramento pós-implantação.

9.1 Componentes

- **Conector/API:** extração incremental autenticada, tolerante a falhas, sem credenciais embutidas.
- **Data lake bruto:** cópia criptografada e imutável para reprodutibilidade.
- **Privacidade:** pseudonimização e cofre de chaves segregado.
- **Modelo canônico:** eventos, sessões, observação, contexto, ABC, planos, estratégias e programas.
- **Feature store:** cálculo temporal reproduzível com versão e data de validade.
- **Treinamento/registry:** experimentos, artefatos, métricas, calibração, aprovação e rollback.
- **Prediction API:** retorna risco, horizonte, incerteza, qualidade do dado, versão e justificativas associativas.
- **Painel clínico:** visualização para profissional autorizado, sem automatizar intervenção.
- **Monitoramento:** drift, calibração, fairness, falhas, incidentes, alertas e resultados clínicos.

9.2 Como o aplicativo calcula e apresenta a probabilidade

No instante t , o serviço consulta ou recebe features com timestamp de validade. O modelo estima $p = P(X \text{ ocorrer em } (t, t+H] \mid \text{informação disponível até } t)$. Se houver calibrador, a pontuação bruta é convertida em probabilidade. Antes de retornar, regras verificam cobertura, missingness, versão da definição do comportamento, distância da distribuição de treino e disponibilidade de um plano clínico. Quando o dado é insuficiente, o sistema deve abster-se.

Exemplo de apresentação

“Probabilidade estimada de agressão física nos próximos 30 minutos: 18% (baseline pessoal para este contexto: 6%). Qualidade do dado: adequada. Fatores associados neste cálculo: aumento de frequência nas últimas 3 sessões, transição para atividade com demanda e maior latência nas tentativas recentes. Esta estimativa não determina causa ou função. Consulte o plano preventivo aprovado.”

Faixas baixo/moderado/alto só devem ser usadas após calibração e definição conjunta de limiares. Mostrar apenas uma cor ou score sem risco absoluto pode induzir interpretação errada. A interface deve permitir feedback sobre qualidade do alerta, mas esse feedback não deve ser incorporado automaticamente ao modelo sem validação e controle de versão.

10. Considerações éticas, clínicas e legais

10.1 Ética clínica e análise do comportamento

O modelo deve favorecer autonomia, segurança, dignidade e acesso a oportunidades. Um risco elevado não autoriza restrição, contenção, exclusão ou redução de demandas sem indicação clínica independente e plano compatível. O sistema não deve ser usado como substituto de supervisão, como critério isolado de desligamento, como ferramenta punitiva de gestão ou para atribuir culpa ao terapeuta.

A previsão deve ser vinculada a respostas proporcionais e de baixo risco, como checagem de comunicação funcional, ajuste antecedente previsto, disponibilidade de reforço, organização de transição e observação mais atenta. O alerta não deve ampliar intervenções intrusivas. A equipe deve ser treinada para compreender falsos positivos, falsos negativos e a diferença entre associação e função.

10.2 LGPD e privacidade

Dados de saúde, biométricos e informações clínicas são dados pessoais sensíveis sob a Lei nº 13.709/2018. O controlador deve definir finalidade específica, hipótese legal aplicável, necessidade, transparência, qualidade, segurança, prevenção, não discriminação e prestação de contas. A hipótese legal não deve ser presumida: assistência, pesquisa e desenvolvimento de produto podem exigir análises distintas. O Guia da ANPD para fins acadêmicos e estudos destaca regimes próprios e a anonimização sempre que possível; quando os dados são apenas pseudonimizados, continuam pessoais.

Devem ser documentados fluxo de dados, responsáveis, operadores, compartilhamentos, retenção, direitos dos titulares, incidentes e avaliação de impacto. Consentimento, quando usado, precisa ser livre, informado, específico e revogável, mas nem sempre será a única ou a melhor base legal; aconselhamento jurídico e do encarregado é necessário.

10.3 Pesquisa com seres humanos e bases de dados

Pesquisas retrospectivas e prospectivas com dados clínicos identificáveis ou pseudonimizados podem exigir submissão ao sistema CEP/CONEP, conforme desenho, instituição e regulamentação aplicável. A Resolução CNS nº 738/2024 disciplina aspectos éticos do uso de bancos de dados para pesquisa envolvendo seres humanos. Devem ser previstos anuência institucional, plano de

acesso/compartilhamento, confidencialidade, justificativa de dispensa de consentimento quando pertinente e gestão de riscos de estigmatização e reidentificação.

10.4 Software como dispositivo médico

A RDC Anvisa nº 657/2022 dispõe sobre regularização de Software as a Medical Device (SaMD). O enquadramento depende da finalidade pretendida, claims, usuário, decisão suportada e risco. Um aplicativo que estima risco clínico e orienta conduta pode demandar análise regulatória; chamar o sistema de “apoio” não o exclui automaticamente. Antes de piloto assistencial, devem ser avaliados classificação, requisitos de qualidade, gestão de risco, segurança, validação, rotulagem, monitoramento pós-mercado e normas correlatas.

10.5 Equidade e viés

Avaliar desempenho por idade, sexo, comunicação, diagnóstico, topografia, função, serviço, profissional e volume de dados é essencial. Alguns grupos podem ter menos eventos registrados, menor tolerância a dispositivos ou definições menos precisas. Um modelo pode aprender padrões de acesso, equipe ou documentação em vez de risco. Calibração e falsos alertas devem ser comparados por subgrupo; divergências relevantes exigem correção, restrição de uso ou abstenção.

10.6 Governança de IA em saúde

A Organização Mundial da Saúde recomenda colocar ética e direitos humanos no centro do design e uso de IA em saúde. Para este projeto, isso significa supervisão humana real, finalidade delimitada, segurança, transparência, responsabilidade, inclusão, avaliação contínua e mecanismos para contestar decisões. Uma comissão de governança multidisciplinar deve incluir analistas do comportamento, ciência de dados, segurança, jurídico/privacidade, pessoas autistas/famílias quando viável e gestão de qualidade (World Health Organization, 2021).

11. Recomendações metodológicas para transformar a pesquisa em MVP

11.1 Escopo mínimo recomendado

- Um comportamento X com definição operacional estável e gravidade clinicamente relevante.
- Um ou poucos serviços com processos de registro semelhantes.
- Dois horizontes iniciais: próxima sessão e próximo dia; adicionar intrassessão após auditoria temporal.
- Dados da bHave sem wearables na primeira versão.
- Baselines + regressão logística/GLMM + sobrevivência em tempo discreto + CatBoost.
- Painel somente de pesquisa/sandbox; nenhuma intervenção automática.

11.2 Fases

Fase	Atividades	Saída
0. Governança	Finalidade, responsáveis, LGPD, CEP/CONEP, análise SaMD, plano de risco e proibições de uso.	Documentação aprovada.
1. Auditoria de dados	Mapear API, ontologia, onsets, cobertura, duplicatas, missingness, mudanças e confiabilidade.	Relatório de viabilidade e dicionário.
2. Coorte retrospectiva	Criar landmarks, baselines e modelos; validação temporal/por paciente; calibração.	Relatório TRIPOD+AI e model card.
3. Validação externa	Testar período/serviço não usado; revisar subgrupos e drift.	Crítérios go/no-go.
4. Prospectivo silencioso	Gerar previsões sem exibir; medir atrasos, abstention e estabilidade.	Evidência de desempenho real.

Fase	Atividades	Saída
5. Simulação clínica	BCBAs revisam alertas e ações; definir limiar e orçamento de falsos alertas.	Protocolo de piloto.
6. Piloto assistido	Alertas limitados e respostas preventivas pré-aprovadas; monitoramento de danos.	Avaliação de utilidade e segurança.

11.3 Critérios de avanço

Os critérios devem ser pré-especificados e adaptados ao risco. Exemplos de metas de governança, não limites universais: AUPRC claramente acima da prevalência; calibração visual aceitável e inclinação próxima de 1; desempenho estável em bootstrap e períodos; número tolerável de falsos alertas; antecedência útil; ausência de degradação grave em subgrupos; benefício líquido positivo; e aceitação clínica sem aumento de restrição. Se o modelo não superar frequência recente ou não calibrar, o projeto deve permanecer analítico e não virar alerta.

11.4 Backlog técnico do MVP

- Conector seguro e testes de contrato da API.
- Modelo canônico e data-quality dashboard.
- Pipeline reproduzível de landmarks e features.
- Notebook/pipeline de baselines e validação agrupada.
- Registro de experimentos e model registry.
- Módulo de calibração e seleção de limiar por utilidade.
- Prediction API com regras de abstenção.
- Painel de pesquisa com risco, baseline, qualidade e explicações.
- Monitor de drift/calibração e trilha de auditoria.
- Documentação: datasheet, model card, plano de risco e manual clínico.

12. Limitações

A literatura ainda contém poucas replicações independentes e muitas amostras pequenas, principalmente em ambientes de internação ou residenciais. Wearables podem excluir participantes que não toleram o dispositivo. Estudos de detecção são frequentemente descritos com linguagem preditiva, e métricas muito altas podem refletir vazamento. A revisão apresentada não é uma revisão sistemática registrada e não acessou de forma exaustiva todas as bases comerciais.

Para a bHave, a maior incerteza é a granularidade real da API: timestamps, cobertura observacional, versionamento de definições e disponibilidade de variáveis antecedentes antes do evento. Mesmo um modelo tecnicamente adequado pode não ser clinicamente útil se não houver ação preventiva segura, se o alerta chegar tarde ou se gerar excesso de falsos positivos. Mudanças de tratamento reduzem a estabilidade do modelo, mas são parte normal e desejável da prática clínica.

13. Conclusão

A previsão de comportamentos-problema em ABA é cientificamente plausível e já apresenta provas de conceito em horizontes de segundos a um dia. A melhor evidência atual favorece modelos temporais simples e rigorosamente validados, personalização parcial, histórico recente e combinação de contexto com dados comportamentais. Algoritmos complexos não garantem melhor desempenho; em estudos robustos, regressão logística foi competitiva ou superior.

Dados da bHave podem alimentar um modelo desde que sejam transformados em instantes de decisão, com features estritamente anteriores ao alvo, períodos de observação conhecidos, validação por paciente/tempo e probabilidades calibradas. O MVP deve começar com um comportamento,

poucos horizontes e baselines fortes, seguido por validação prospectiva silenciosa. O resultado ao profissional deve ser uma estimativa de risco com baseline, incerteza, qualidade do dado e fatores associados, conectada a um plano preventivo previamente aprovado.

O sistema não deve determinar função, prescrever automaticamente ou substituir o julgamento clínico. Seu valor está em organizar sinais distribuídos ao longo do tempo, quantificar incerteza e apoiar uma atenção preventiva mais consistente. A implementação responsável exige LGPD, ética em pesquisa, possível avaliação de SaMD, governança multidisciplinar, monitoramento contínuo e participação clínica desde a definição do alvo até a revisão de erros.

14. Referências (APA 7ª edição)

- Alban, A. Q., Alhaddad, A. Y., Al-Ali, A., So, W.-C., Connor, O., Ayesh, M., Ahmed Qidwai, U., & Cabibihan, J.-J. (2023). Heart rate as a predictor of challenging behaviours among children with autism from wearable sensors in social robot interactions. *Robotics*, 12(2), 55. <https://doi.org/10.3390/robotics12020055>
- Agência Nacional de Proteção de Dados. (2023). Tratamento de dados pessoais para fins acadêmicos e para a realização de estudos e pesquisas. Governo Federal do Brasil.
- Agência Nacional de Vigilância Sanitária. (2022). Resolução da Diretoria Colegiada—RDC nº 657, de 24 de março de 2022: Dispõe sobre a regularização de software como dispositivo médico (Software as a Medical Device—SaMD).
- Brasil. (2018). Lei nº 13.709, de 14 de agosto de 2018: Lei Geral de Proteção de Dados Pessoais (LGPD). Presidência da República.
- Cantin-Garside, K. D., Kong, Z., White, S. W., Antezana, L., Kim, S., & Nussbaum, M. A. (2020). Detecting and classifying self-injurious behavior in autism spectrum disorder using machine learning techniques. *Journal of Autism and Developmental Disorders*, 50, 4039–4052. <https://doi.org/10.1007/s10803-020-04463-x>
- Cantin-Garside, K. D., Srinivasan, D., Ranganathan, S., White, S. W., & Nussbaum, M. A. (2020). Multi-level modeling with nonlinear movement metrics to classify self-injurious behaviors in autism spectrum disorder. *Scientific Reports*, 10, 16699. <https://doi.org/10.1038/s41598-020-73155-4>
- Cohen, S., Fulcher, B. D., Rajaratnam, S. M. W., Conduit, R., Sullivan, J. P., St Hilaire, M. A., Phillips, A. J. K., Loddenkemper, T., Kothare, S. V., McConnell, K., Braga-Kenyon, P., Ahearn, W., Shlesinger, A., Potter, J., Bird, F., Cornish, K. M., & Lockley, S. W. (2018). Sleep patterns predictive of daytime challenging behavior in individuals with low-functioning autism. *Autism Research*, 11(2), 391–403. <https://doi.org/10.1002/aur.1899>
- Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., Van Calster, B., Ghassemi, M., Liu, X., Reitsma, J. B., van Smeden, M., Boulesteix, A.-L., Camaradou, J. C., Celi, L. A., Denaxas, S., Denniston, A. K., Glocker, B., Golub, R. M., Harvey, H., Heinze, G., ... Logullo, P. (2024). TRIPOD+AI statement: Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385, e078378. <https://doi.org/10.1136/bmj-2023-078378>
- Conselho Nacional de Saúde. (2016). Resolução nº 510, de 7 de abril de 2016: Normas aplicáveis a pesquisas em Ciências Humanas e Sociais.
- Conselho Nacional de Saúde. (2024). Resolução nº 738, de 1º de fevereiro de 2024: Uso de bancos de dados com finalidade de pesquisa científica envolvendo seres humanos.
- Ferina, J., Dando, E., Anderson, C., Foster, J., Lantz, J., Hamlin, T., & Hahn, J. (2025). Approaches for predicting the occurrence of challenging behaviors in individuals with autism spectrum disorder: A

- narrative review. *Journal of Personalized Medicine*, 15(10), 453.
<https://doi.org/10.3390/jpm15100453>
- Ferina, J., Kruger, M., Kruger, U., Ryan, D., Anderson, C., Foster, J., Hamlin, T., & Hahn, J. (2023). Predicting problematic behavior in autism spectrum disorder using medical history and environmental data. *Journal of Personalized Medicine*, 13(10), 1513.
<https://doi.org/10.3390/jpm13101513>
- Goodwin, M. S., Mazefsky, C. A., Ioannidis, S., Erdogmus, D., & Siegel, M. (2019). Predicting aggression to others in youth with autism using a wearable biosensor. *Autism Research*, 12(8), 1286–1296. <https://doi.org/10.1002/aur.2151>
- Imbiriba, T., Demirkaya, A., Singh, A., Erdogmus, D., & Goodwin, M. S. (2023). Wearable biosensing to predict imminent aggressive behavior in psychiatric inpatient youths with autism. *JAMA Network Open*, 6(12), e2348898. <https://doi.org/10.1001/jamanetworkopen.2023.48898>
- Iwata, B. A., Dorsey, M. F., Slifer, K. J., Bauman, K. E., & Richman, G. S. (1994). Toward a functional analysis of self-injury. *Journal of Applied Behavior Analysis*, 27(2), 197–209.
<https://doi.org/10.1901/jaba.1994.27-197>
- Khullar, V., Singh, H. P., & Bala, M. (2021). Meltdown/tantrum detection system for individuals with autism spectrum disorder. *Applied Artificial Intelligence*, 35(15), 1708–1732.
<https://doi.org/10.1080/08839514.2021.1991115>
- Kiarashi, Y., Lantz, J., Reyna, M. A., Anderson, C., Rad, A. B., Foster, J., Villavicencio, T., Hamlin, T., & Clifford, G. D. (2025). Predicting seizure episodes and high-risk events in autism through adverse behavioral patterns. *Physiological Measurement*, 46(4), 045008. <https://doi.org/10.1088/1361-6579/adcafd>
- Kiarashi, Y., Suresha, P. B., Rad, A. B., Reyna, M. A., Anderson, C., Foster, J., Lantz, J., Villavicencio, T., Hamlin, T., & Clifford, G. D. (2024). Off-body sleep analysis for predicting adverse behavior in individuals with autism spectrum disorder. *IEEE Journal of Biomedical and Health Informatics*, 28(11), 6886–6896. <https://doi.org/10.1109/JBHI.2024.3455942>
- Kim, S., Cantin-Garside, K. D., & Nussbaum, M. A. (2026). Feasibility of forecasting self-injurious behavior among autistic youth using wearable sensors and machine learning models. *Scientific Reports*, 16, 20203. <https://doi.org/10.1038/s41598-026-50079-z>
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In I. Guyon et al. (Eds.), *Advances in Neural Information Processing Systems 30* (pp. 4765–4774). Curran Associates.
- Moons, K. G. M., Damen, J. A. A. G., Kaul, T., Hooft, L., Andaur Navarro, C. L., Dhiman, P., Beam, A. L., Van Calster, B., Ghassemi, M., Liu, X., Reitsma, J. B., van Smeden, M., Boulesteix, A.-L., Collins, G. S., & Wolff, R. F. (2025). PROBAST+AI: An updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388, e082505. <https://doi.org/10.1136/bmj-2024-082505>
- Nuske, H. J., Finkel, E., Hedley, D., Parma, V., Tomczuk, L., Pellecchia, M., Herrington, J., Marcus, S. C., Mandell, D. S., & Dissanayake, C. (2019). Heart rate increase predicts challenging behavior episodes in preschoolers with autism. *Stress*, 22(3), 303–311.
<https://doi.org/10.1080/10253890.2019.1572744>
- Rad, A. B., Villavicencio, T., Kiarashi, Y., Anderson, C., Foster, J., Kwon, H., Hamlin, T., Lantz, J., & Clifford, G. D. (2025). From motion to emotion: Exploring challenging behaviors in autism spectrum disorder through analysis of wearable physiology and movement. *Physiological Measurement*, 46(1), 015004. <https://doi.org/10.1088/1361-6579/ada51b>

- Romani, P. W., D'Mello, S. K., Moulder, R. M., & Berkowitz, L. N. (2026). Using wearable technology to predict the occurrence of severe behavior problems among neurodiverse individuals: A systematic review. *Perspectives on Behavior Science*, 49, 361–383. <https://doi.org/10.1007/s40614-026-00497-1>
- Saito, T., & Rehmsmeier, M. (2015). The precision–recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), e0118432. <https://doi.org/10.1371/journal.pone.0118432>
- Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., & Steyerberg, E. W. (2019). Calibration: The Achilles heel of predictive analytics. *BMC Medicine*, 17, 230. <https://doi.org/10.1186/s12916-019-1466-7>
- World Health Organization. (2021). Ethics and governance of artificial intelligence for health: WHO guidance. World Health Organization. ISBN 978-92-4-002920-0.
- Zheng, Z. K., Staubitz, J. E., Weitlauf, A. S., Staubitz, J., Pollack, M., Shibley, L., Hopton, M., Martin, W., Swanson, A., & Juárez, P. (2021). A predictive multimodal framework to alert caregivers of problem behaviors for children with ASD (PreMAC). *Sensors*, 21(2), 370. <https://doi.org/10.3390/s21020370>

Apêndice A. Esquema mínimo de dados para o MVP

Tabela	Campos mínimos	Observações
patient	patient_token, service_id, demographics_coarsened	Sem identificadores diretos; idade/faixa e características apenas se justificadas.
session	session_id, patient_token, start_ts, end_ts, setting, therapist_token, session_type	Define exposição/observação.
behavior_event	event_id, session_id, behavior_code, onset_ts, offset_ts, intensity, definition_version	Fonte do alvo; onset obrigatório para intrassessão.
abc_record	record_id, event_id, antecedent_code, consequence_code, function_hypothesis, confidence	Códigos padronizados e validade temporal.
context_state	patient_token, valid_from, valid_to, activity, environment, demand, people_present	Permite join temporal “as of”.
intervention_exposure	patient_token, strategy_code, start_ts, end_ts, integrity, plan_version	Somente exposição anterior à previsão.
program_trial	trial_id, timestamp, program, response, prompt, independence, latency	Agregação por janelas; evitar resumo futuro.
health_routine	patient_token, date/time, sleep, GI, illness, medication_change	Governança reforçada; dados opcionais.
data_quality	entity_id, entry_delay, missing_fields, observer, audit_flag	Permite abstenção e análise de viés.

Apêndice B. Checklist anti-vazamento

- A feature existia e estava registrada antes do instante de decisão?
- O total da sessão ou consequência foi calculado após o evento?
- O mesmo paciente aparece em treino e teste quando a alegação é generalização a novos pacientes?
- Janelas sobrepostas do mesmo episódio foram separadas entre treino e teste?
- Normalização, imputação, seleção de features e oversampling foram ajustados apenas no treino?
- O limiar e a calibração foram definidos fora do teste?
- O identificador de paciente/terapeuta está memorizando padrões?
- Períodos sem registro foram tratados indevidamente como ausência de comportamento?

- A definição operacional mudou entre períodos?
- O baseline foi calculado sem usar informação futura?

Apêndice C. Saída mínima da Prediction API

Campo	Descrição
patient_token	Identificador pseudônimo.
landmark_ts	Instante da decisão.
behavior_code	Comportamento operacionalizado.
horizon	15m, 30m, session, next_session, next_day etc.
risk_probability	Probabilidade calibrada.
personal_baseline	Risco histórico comparável, calculado sem futuro.
uncertainty	Intervalo ou indicador de confiança.
data_quality	adequate/limited/insufficient.
abstain	true/false e motivo.
associated_factors	Top fatores locais, não causais.
model_version	Modelo, calibrador e feature pipeline.
clinical_plan_ref	Referência ao plano aprovado; nunca uma intervenção nova.
audit_id	Identificador da trilha de auditoria.

PARTE II - Implementação MVP integrada ao artigo

Objetivo da integração. A revisão acadêmica demonstrou que modelos preditivos para comportamentos-problema exigem separação temporal, cuidado com eventos raros, probabilidades calibradas, interpretabilidade, governança clínica e proteção de dados. A implementação MVP materializa esses requisitos em uma arquitetura local testável, sem alegar prontidão para uso clínico real.

Aviso clínico e regulatório. A previsão gerada pelo MVP é ferramenta de apoio. Ela não substitui avaliação funcional, julgamento do analista do comportamento, decisão clínica supervisionada nem revisão jurídica/regulatória para uso com dados sensíveis reais.

1. Arquitetura implementada

- Backend FastAPI separado para o MVP preditivo, com endpoints de configuração, sincronização, treino, previsão, modelos, drift, relatórios e governança.
- Frontend React/Vite operacional para sincronizar dados mock, selecionar paciente/comportamento, treinar, prever, visualizar risco, fatores associados, gráfico histórico e histórico de previsões.
- Armazenamento local SQLite/JSON para registros, métricas, histórico de previsões e auditoria; artefatos de modelo versionados em storage/models.
- Modo mock com 5 pacientes, 5 comportamentos-alvo e múltiplas sessões com variação de frequência, duração, intensidade, ambiente, antecedente, consequência, hipótese funcional, prompt e independência.

2. Adapter bHave ajustável ao contrato real

- O adapter deixou de depender de uma rota única fixa e passou a aceitar caminho de registros, esquema de autenticação, cabeçalho, chave de payload, paginação e limite de páginas por configuração.
- O endpoint GET /api/config/bhave/contract permite auditar se base URL, token e parâmetros de contrato estão configurados antes da sincronização.
- Como o contrato oficial final da API bHave ainda precisa ser confirmado em ambiente real, a implementação prioriza adaptabilidade e isolamento do restante do pipeline.

3. Calibração explícita de probabilidade

- O treino agora usa holdout temporal e, quando há dados suficientes com duas classes, aplica Platt scaling em conjunto de calibração separado.
- A calibração fica registrada na metadata do modelo, incluindo método, status calibrado e quantidade de amostras usadas.
- Quando a amostra não permite calibração segura, o sistema registra o motivo e evita declarar calibração inexistente.

4. Persistência versionada de modelos

- Cada treino gera um version_id com data UTC, paciente ou escopo geral e comportamento-alvo.
- O modelo selecionado é salvo em joblib e acompanhado por metadata JSON com métricas, validação, calibração, taxa histórica, amostras e estatísticas de referência.
- O endpoint GET /api/ml/models lista o índice de versões disponíveis para rastreabilidade técnica.

5. Validação temporal, por paciente e por período

- A divisão treino/teste usa ordenação temporal, evitando embaralhamento aleatório de séries clínicas.

- O resultado do treino inclui periodo de treino, periodo de teste, cutoff temporal, fatias por paciente e fatias por mes.
- As fatias registram amostras, taxa de evento, probabilidade media e acuracia, permitindo detectar desempenho desigual entre pacientes ou periodos.

6. Drift de dados e desempenho

- Durante o treino sao salvas estatisticas de referencia das features numericas e categoricas.
- O endpoint GET /api/ml/drift compara os dados atuais com a referencia do modelo e retorna status baixo, moderado ou alto.
- O drift numerico usa deslocamento de media em z-score; o drift categorico usa distancia total de variacao e lista novos valores.

7. LGPD, governanca clinica e enquadramento regulatorio

- O endpoint GET /api/governance/lgpd retorna production_use_allowed=false por padrao.
- O checklist exige base legal, finalidade especifica, pseudonimizacao, politica de retencao, DPIA/RIPD, revisao de vies, revisao humana e avaliacao regulatoria SaMD/software medico.
- Antes de qualquer uso real, o sistema requer parecer juridico LGPD, governanca clinica documentada, validacao prospectiva silenciosa, controle de acesso e trilha de auditoria imutavel.

8. Componentes tecnicos e responsabilidade

Componente	Arquivo principal	Responsabilidade
Adapter bHave	backend/app/services/bhave_client.py	Contrato configuravel, autenticacao, payload e paginacao.
Normalizacao	backend/app/services/normalizer.py	Mapeamento para schema canonico e preparo dos registros.
Features	backend/app/ml/features.py	Janelas temporais e atributos contextuais.
Treino	backend/app/ml/training.py	Baseline, regressao logistica, Random Forest, calibracao e selecao.
Model store	backend/app/ml/model_store.py	Persistencia joblib, metadata JSON e indice de versoes.
Validacao	backend/app/ml/validation.py	Holdout temporal e fatias por paciente/periodo.
Drift	backend/app/ml/drift.py	Comparacao de distribuicoes contra referencia do treino.
Governanca	backend/app/services/governance.py	Checklist LGPD, clinico e regulatorio.

9. Endpoints adicionados ou atualizados

Endpoint	Finalidade
GET /api/config/bhave/contract	Auditar configuracao do contrato bHave.
POST /api/ml/train	Treinar, calibrar, validar e versionar modelo.
POST /api/ml/predict	Carregar modelo em memoria ou do disco e gerar previsao calibrada.
GET /api/ml/models	Listar indice de modelos versionados.
GET /api/ml/drift	Monitorar drift contra baseline do treino.
GET /api/governance/lgpd	Expor checklist LGPD/governanca/regulatorio e bloqueio de producao.

10. Estado atual de verificacao

- Testes automatizados do modulo bHave executados com sucesso: 23 passed.
- Foram adicionados registros de fix em docs/fixes no padrao 13_07_26_fixN.md.
- A renderizacao visual do DOCX depende de LibreOffice/soffice disponivel no ambiente; a verificacao estrutural e feita com python-docx quando o renderer nao esta disponivel.

PARTE III - Logica matematica, evolucao clinica e explicabilidade operacional

Resumo da atualizacao. Esta parte integra a revisao academica ao MVP implementado: mostra como os dados da bHave entram no contrato canonico, como as evolucoes/anotacoes sao transformadas em variaveis, quais equacoes sustentam as previsoes e quais salvaguardas impedem uso clinico indevido.

1. Visao geral da logica do sistema

A logica do aplicativo foi desenhada como uma cadeia temporal. Cada sessao do paciente gera registros estruturados e, quando disponivel, texto clinico. Esses dados sao normalizados, convertidos em features e usados para estimar uma probabilidade futura. A probabilidade nao e uma decisao automatica; ela e um sinal analitico para apoiar a leitura do analista do comportamento.



Figura 1. Fluxo logico do dado ate a previsao calibrada.

Parte	Pergunta que responde	Entrada	Saida
Adapter bHave	O dado veio no contrato esperado?	API real, mock ou arquivo normalizado	Schema canonico auditavel
Feature engineering	O que ja era conhecido antes da previsao?	Historico ate t	Vetor X_t sem vazamento
Extracao de anotacoes	O texto clinico contem sinal comportamental?	Evolucoes e notas	Features textuais revisaveis
Modelo preditivo	Qual a chance de ocorrer no horizonte H?	X_t	$p(Y_{t,h} = 1 X_t)$
Calibracao	70% significa aproximadamente 70%?	Probabilidade bruta + validacao	Probabilidade calibrada
Governanca	Pode ser usado com seguranca?	Metricas, drift, LGPD, auditoria	Status de uso permitido ou bloqueado

2. Variavel-alvo e horizonte de previsao

Para comportamento-problema, a variavel-alvo e binaria. Em cada sessao t, o sistema pergunta se o comportamento X ocorrera em uma janela futura h. No MVP, h costuma representar a proxima sessao, mas o contrato aceita horizontes configuraveis.

Equacao 1 - alvo temporal

$Y_{\{t,h\}} = 1$ se o comportamento X ocorrer na janela futura h

$Y_{\{t,h\}} = 0$ se o comportamento X nao ocorrer na janela futura h

$$p_{\{t,h\}} = P(Y_{\{t,h\}}=1 \mid X_t)$$

O vetor X_t contém somente informações conhecidas até a sessão t . Essa regra evita vazamento de informação futura.

3. Previsão de habilidades e objetivos

Para habilidades e objetivos, o foco não é apenas classificar risco. O sistema estima a trajetória de independência ao longo dos meses. Se um paciente apresenta 70% de independência no mês 1, 20% no mês 2 e 100% no mês 3, a aplicação calcula uma tendência suavizada, limita a previsão entre 0% e 100% e informa a probabilidade de atingir o critério clínico.




Figura 2. Exemplo de previsão mensal de independência a partir de três meses observados.

Equação 2 - tendência ponderada de independência

I_m = independência média observada no mês m

$$b = \frac{\text{soma}[w_m (m - m_{\text{barra}})(I_m - I_{\text{barra}})]}{\text{soma}[w_m (m - m_{\text{barra}})^2]}$$

$$I_{\text{hat}}_{\{m+h\}} = \text{clip}(I_m + h \cdot b, 0, 100)$$

$$P(\text{meta}) = \text{sigmoid}((I_{\text{hat}}_{\{m+h\}} - \theta) / \sigma)$$

Pesos maiores podem ser dados aos meses recentes. θ representa o critério clínico, por exemplo 80% de independência; σ controla quão abrupta é a transição de probabilidade.

Leitura clínica. Uma queda de 70% para 20% e depois subida para 100% não deve ser interpretada como linha reta simples. O sistema exibe tendência, variabilidade e critério, permitindo que o profissional avalie se a oscilação reflete aprendizagem, mudança de demanda, prompt, ambiente ou registro inconsistente.

4. Previsão de comportamento-problema

Para comportamento-problema, o MVP combina baseline histórico, risco recente, janelas móveis, contexto, antecedentes, consequências e features textuais. A previsão final é uma probabilidade calibrada, acompanhada de fatores explicativos e classificação de risco.




Figura 3. Exemplo de contagem observada e probabilidade calibrada por sessão.

Equacao 3 - risco recente exponencial

$$R_t = \alpha \cdot y_t + (1 - \alpha) \cdot R_{t-1}$$

$F_{\text{recente}}(t, N)$ = soma dos eventos nas ultimas N sessoes

p_{baseline} = sessoes com ocorrencia / sessoes observadas

O parametro alpha controla quanto o evento mais recente pesa na avaliacao. Valores maiores tornam o risco mais sensivel ao ultimo registro.

Equacao 4 - modelo probabilistico

$$z = \beta_0 + \beta_1 \cdot x_1 + \dots + \beta_n \cdot x_n$$

$$p_{\text{bruto}} = 1 / (1 + \exp(-z))$$

$$p_{\text{calibrado}} = \text{sigmoid}(a \cdot p_{\text{bruto}} + b)$$

A regressao logistica fornece uma probabilidade bruta. A calibracao ajusta essa saida para que a interpretacao percentual seja mais confiavel.

5. Como as evolucoes e anotacoes entram no modelo

As evolucoes clinicas e anotacoes de atendimento foram adicionadas como fonte complementar. O sistema nao assume que todo texto e verdade operacional final: ele extrai sinais, marca ambiguidade e permite correcao humana.




Figura 4. Pipeline de extração de anotações clínicas para features preditivas.

Equação 5 - transformação textual em features

```

s_limpo = normalizar(texto_bruto)
o_b in {0, 1, nulo} para cada comportamento b
X_t = [features_estruturadas_t, features_textuais_t]
prioridade = correcao humana > dado estruturado > extração automática > desconhecido
Negações reduzem ocorrência; termos ambíguos reduzem confiança e acionam revisão humana.
Correções humanas confirmadas passam a ter prioridade.
  
```

- Termos como 'não houve', 'sem' e 'ausência de' são tratados como negação.
- Termos como 'pareceu', 'possível', 'quase' e 'tentou' indicam incerteza.
- Frequência, intensidade, duração, antecedente, consequência e contexto viram colunas numéricas ou binárias.
- A revisão humana corrige falsos positivos, falsos negativos e ambiguidades clínicas.

6. Validação temporal, calibração e monitoramento

A validação precisa respeitar o tempo e a identidade do paciente. Misturar sessões futuras no treino ou testar no mesmo período usado para escolher limiar gera desempenho artificialmente alto. Por isso, a avaliação é feita com corte temporal e monitoramento contínuo.

Equação 6 - Brier Score e drift

```

BS = media((p_i - y_i)^2)
PSI = soma_i (p_i - q_i) * ln(p_i / q_i)
  
```

O Brier Score mede qualidade probabilística. O PSI compara distribuições entre referência e produção para sinalizar drift de dados.

Controle	Logica	Motivo clinico
Split temporal	Treino em sessoes antigas; teste em sessoes recentes	Simula previsao real
Agrupamento por paciente	Metricas por paciente e periodo	Evita esconder heterogeneidade
Calibracao	Brier, curva de calibracao e Platt/isotonic quando aplicavel	Torna o percentual interpretavel
Drift	Comparacao de distribuicao e desempenho	Detecta mudanca de ambiente, registro ou perfil
Abstencao	Bloqueio quando dado esta fora do dominio	Evita alerta com baixa confianca

7. Interpretacao dos resultados no painel

A leitura recomendada segue quatro perguntas: a probabilidade esta acima do baseline? O risco recente explica a mudanca? Existem anotacoes textuais confirmando o padrao? As metricas e o drift permitem confiar no modelo neste periodo?

- Risco baixo: $p < 0,30$; normalmente monitoramento e revisao de rotina.
- Risco moderado: $0,30 \leq p < 0,70$; revisar contexto, antecedentes, consequencias e tendencia.
- Risco alto: $p \geq 0,70$; exige leitura clinica cuidadosa, mas nao autoriza intervencao automatica.
- Probabilidade alta com baixa confianca textual ou drift ativo deve ser tratada como alerta tecnico, nao como conclusao clinica.

8. Limites, LGPD e uso real

Limite regulatorio. O artigo e o MVP descrevem apoio a decisao e pesquisa aplicada. Antes de uso real, e necessario revisar LGPD, governanca clinica, auditoria, consentimento/base legal, seguranca, vieses e possivel enquadramento regulatorio como software em saude.

A previsao nao substitui avaliacao funcional, julgamento profissional, analise de contingencias nem decisao do analista do comportamento. O modelo descreve padroes observados nos dados disponiveis; ele nao prova causa, funcao comportamental ou eficacia de intervencao.

9. Atualizacao do estado de verificacao

- Testes automatizados do modulo bHave executados com sucesso: 23 passed.
- Foram adicionadas features textuais derivadas de evolucoes/anotacoes de atendimento.
- Foram adicionados endpoints de atendimentos, extracao, revisao humana e features from-notes.
- Foi registrado documento de fix em docs/fixes/13_07_26_fix16.md.